

Abordagens baseadas em IA para o reconhecimento da Língua Brasileira de Sinais: Uma Revisão Sistemática da Literatura

Insights sobre métodos, métricas e recursos para o reconhecimento de LIBRAS

Victor Costa
vrcosta@inf.ufpel.edu.br
PPGC, ViTech - UFPel
Pelotas/RS, Brasil

João Pedro Tomaszewski,
jpto
maszewski@inf.ufpel.edu.br,
PPGC - UFPel, Pelotas/RS, Brasil

Lucas Pereira
lspereira
@inf.ufpel.edu.br PPGC -
UFPel Pelotas/RS, Brasil

Brenda Salenave Santana
bssalenave@inf.ufpel.edu.br
PPGC - UFPel Pelotas/RS, Brasil

Guilherme Corrêa
gcorrea@inf.ufpel.edu.br
PPGC, ViTech - UFPel
Pelotas/RS, Brasil

RESUMO

Esta Revisão Sistemática da Literatura (RSL) investiga a aplicação de Inteligência Artificial (IA), especificamente com técnicas de Visão Computacional (VC) e Processamento de Linguagem Natural (PNL), para o reconhecimento, tradução e interpretação da Língua Brasileira de Sinais (LIBRAS). Seguindo o protocolo PRISMA e utilizando a ferramenta Parsifal para apoiar a definição do protocolo e a gestão do estudo, foram identificados inicialmente 77 estudos. Após remover duplicatas e aplicar critérios de exclusão, foram selecionados 23 estudos para análise aprofundada. A revisão aborda três questões de pesquisa: (i) as soluções baseadas em IA atualmente utilizadas para o reconhecimento da LIBRAS, (ii) as métricas de desempenho e os resultados de avaliação relatados, e (iii) os conjuntos de dados utilizados para treinamento e teste, juntamente com suas características e limitações. Os resultados destacam os avanços nas arquiteturas de aprendizado profundo e nas pipelines de visão computacional, ao mesmo tempo em que revelam desafios persistentes, como a limitada integração de características não manuais, a escassez de conjuntos de dados em larga escala e multimodais, as dificuldades no reconhecimento contínuo de sinais, as práticas heterogêneas de anotação e a inadequação de métricas de avaliação bilíngues para capturar as diferenças sintáticas e semânticas entre a LIBRAS e o português. Além disso, fatores relacionados ao implantação, incluindo o tempo de inferência e o custo computacional, permanecem pouco explorados. Essas informações fornecem orientação para futuras pesquisas em direção a sistemas de reconhecimento da LIBRAS mais precisos, eficientes e inclusivos.

PALAVRAS-CHAVE

Reconhecimento de Língua de Sinais, Língua de Sinais Brasileira, LIBRAS, Inteligência Artificial, Redes Neurais, Revisão Bibliográfica

1 INTRODUÇÃO

LIBRAS (LÍngua BRasileira de Sinais – Língua Brasileira de Sinais) é uma linguagem visuoespacial fundamental para a comunidade surda no Brasil, oficialmente reconhecida por lei [39, 40]. Apesar de seu papel crucial na comunicação individual, políticas públicas, direitos civis e inclusão social, LIBRAS ainda é relativamente pouco difundida.

Essa realidade destaca a necessidade urgente de soluções que possam preencher as lacunas de comunicação e promover a inclusão de pessoas surdas e com deficiência auditiva.

Neste contexto, a Inteligência Artificial (IA), o Aprendizado de Máquina (ML), o Processamento de Linguagem Natural (PNL), o Aprendizado Profundo (DL) e a Visão Computacional (CV) surgem como vias altamente promissoras para o desenvolvimento de sistemas capazes de reconhecer e interpretar a língua de sinais, convertendo-as em texto ou fala [1]. Essas tecnologias têm o potencial de capacitar pessoas surdas e com deficiência auditiva, permitindo uma comunicação mais eficiente e independente. Aplicações práticas, como soluções baseadas em IA para interpretação em tempo real utilizando CV e motores de IA originais, demonstram as capacidades tangíveis e o potencial significativo dessas tecnologias [67]. Tais soluções são tipicamente desenvolvidas com base em grandes conjuntos de dados de vídeos LIBRAS, que são utilizados para treinar algoritmos capazes de identificar posições de mãos, pontos de articulação digital e o fluxo de frases. A aplicação de IA, ML e CV em LIBRAS vai além da simples solução de problemas técnicos; trata-se de um desafio social significativo relacionado à inclusão e comunicação para a comunidade surda no Brasil.

Embora várias revisões sistemáticas tenham explorado vários aspectos do processamento de línguas de sinais com tecnologia, uma lacuna significativa persiste na literatura para uma síntese abrangente e atualizada das soluções específicas para o reconhecimento de LIBRAS. Por exemplo, uma revisão sistemática de Kahlon e Singh [32] focou exclusivamente na tradução de texto para língua de sinais, excluindo conscientemente estudos sobre o reconhecimento de línguas de sinais da sua análise. Outras revisões abrangentes, como a de ZainEldin et al. [67], oferecem uma visão geral da IA na comunicação para pessoas surdas e com deficiência auditiva, mas não se especializam nos desafios únicos linguísticos e técnicos do LIBRAS. Além disso, revisões que abordam aspectos específicos, como a de Prietch et al. [41], frequentemente se concentram em estudos centrados no usuário e considerações éticas, em vez de nos modelos técnicos e métricas de desempenho. Essas obras, embora valiosas, destacam a ausência de uma revisão dedicada. Nosso trabalho aborda diretamente essa necessidade, fornecendo uma análise detalhada das soluções baseadas em IA especificamente para o reconhecimento e interpretação de gestos de LIBRAS, preenchendo assim uma lacuna crítica e consolidando o estado da arte neste domínio especializado.

Esta Revisão Sistemática da Literatura (SLR) tem como objetivo preencher uma lacuna no conhecimento atual e fornecer uma compreensão abrangente e atualizada do estado da arte na aplicação de IA, ML, DL e CV para a tradução, reconhecimento e interpretação de LIBRAS. Ao fazê-lo, busca atender à necessidade de uma síntese rigorosa de evidências empíricas disponíveis, informando pesquisadores e profissionais sobre os avanços e desafios nesta área. A utilização do método de SLR permite uma revisão sistemática e a identificação de trabalhos acadêmicos relevantes, onde cada etapa adere a protocolos estabelecidos. Essa abordagem garante uma compilação e análise rigorosas, imparciais e replicáveis do conhecimento existente, evitando a identificação ou avaliação subjetiva e contribuindo com insights valiosos sobre o reconhecimento de LIBRAS baseado em IA. Esta revisão se concentrará especificamente em trabalhos publicados nos últimos dez anos (2015-2025) para capturar os avanços mais recentes neste campo em rápida evolução.

Este artigo está organizado em oito seções, cada uma abordando um componente-chave da revisão sistemática. A Seção 2 introduz as tecnologias fundamentais relacionadas ao reconhecimento e tradução da Língua Brasileira de Sinais (LIBRAS), com ênfase em Visão Computacional e Processamento de Linguagem Natural. A Seção 3 detalha o processo de revisão sistemática, incluindo as questões de pesquisa, critérios de inclusão e exclusão, bancos de dados consultados e estratégia de seleção de estudos. A Seção 4 descreve os principais resultados obtidos a partir dos estudos selecionados, estruturados em torno das questões de pesquisa definidas. A Seção 5 analisa tendências, divergências e limitações metodológicas identificadas nas obras revisadas. A Seção 6 destaca lacunas de pesquisa, desafios não resolvidos e sugestões para investigações futuras. A Seção 7 resume as principais contribuições da revisão e reforça sua relevância para o campo. Finalmente, a Seção 8 discute as possíveis ameaças à validade e as limitações do processo de revisão.

2 BACKGROUND

Para entender a aplicação da IA na tradução e reconhecimento da LIBRAS, é importante revisar as tecnologias fundamentais introduzidas anteriormente neste artigo: CV e NLP. Estes campos têm avançado significativamente nos últimos anos, permitindo sistemas de tradução robustos, precisos e, em muitos casos, em tempo real.

No contexto da tradução e reconhecimento de LIBRAS, a CV é responsável por capturar e interpretar os aspectos visuais da linguagem de sinais, incluindo gestos das mãos, expressões faciais e postura corporal [12]. A NLP, por sua vez, estrutura e interpreta os gestos reconhecidos em unidades linguísticas coerentes, permitindo sua tradução para texto ou fala [25]. O uso combinado de CV e NLP forma a base de pipelines de ponta a ponta capazes de processar LIBRAS em vídeos e fornecer resultados consistentes [5, 10].

As seções subsequentes descrevem os princípios, métodos e aplicações principais dessas tecnologias no contexto do reconhecimento e tradução de LIBRAS, fornecendo a base para análises subsequentes de modelos, conjuntos de dados e resultados.

2.1 Visão Computacional

Nos sistemas de reconhecimento e tradução de LIBRAS, a Visão Computacional (CV) atua como o componente central responsável por transformar

a entrada visual bruta capturada por câmeras ou sensores em representações que podem ser processadas por modelos de inteligência artificial. Além de simplesmente detectar a presença de mãos ou corpos, a CV moderna analisa padrões espaciais e temporais complexos, permitindo a detecção de gestos dinâmicos, a segmentação precisa de regiões de interesse e a extração de recursos multimodais (mãos, rosto, corpo) [5, 13, 48]. Essas capacidades decorrem da evolução de arquiteturas e métodos que vão desde descritores manuais e segmentação semântica até redes neurais profundas especializadas. Os parágrafos subsequentes apresentam estudos que exploram diferentes estratégias de CV aplicadas ao LIBRAS, destacando avanços recentes, desafios e inovações.

Diversos estudos exploraram várias técnicas de CV para o reconhecimento de LIBRAS. Por exemplo, da Silva et al. [15] propuseram uma arquitetura multi-fluxo para o reconhecimento de sinais no contexto da saúde, integrando pistas espaciais e temporais para melhorar o desempenho em aplicações específicas de domínio. Da mesma forma, da Silva et al. [16] apresentaram um modelo de duas fontes baseado em redes neurais convolucionais 3D (CNN), demonstrando o reconhecimento eficaz de gestos dinâmicos por meio da integração de características de movimento e aparência.

A segmentação de gestos é outro componente fundamental no reconhecimento de sinais. Sarma et al. [52] empregaram modelos baseados em atenção para segmentação semântica de mãos, alcançando a localização precisa de regiões de mãos em fundos complexos, o que é essencial para isolar gestos de entradas visuais ruidosas. Além disso, Jyoti Dutta et al. [31] exploraram técnicas de segmentação semântica usando redes neurais profundas para melhorar o reconhecimento de gestos em sequências contínuas de sinais.

Abordagens baseadas em esqueleto também ganharam atenção devido à sua robustez e eficiência. Alves et al. [4] propuseram o uso de representações de imagem esqueléticas para melhorar o reconhecimento em LIBRAS, reduzindo a carga computacional ao mesmo tempo em que preservam informações de gestos críticas. Esses métodos são particularmente adequados para dispositivos móveis ou de baixo consumo de energia. Da mesma forma, Fanucchi et al. [24] aperfeiçoaram um autoencoder de máscara de vídeo para reconhecimento de sinais em aplicações de realidade aumentada, exemplificando a integração da visão computacional com tecnologias imersivas para atender às necessidades de comunicação do mundo real.

Sistemas de reconhecimento de gestos baseados em aprendizado profundo frequentemente dependem de grandes conjuntos de dados. Nesse contexto, Bharti et al. [9] introduziram uma técnica de extração de quadros-chave baseada em correção de erros para melhorar o reconhecimento de gestos de mãos dinâmicas, visando reduzir a redundância temporal ao mesmo tempo em que preserva a integridade dos gestos. Silveira et al. [55] e Silveira et al. [56] exploraram modelos generativos para sintetizar gestos em LIBRAS, permitindo a criação de sinalização digital e contribuindo para a ampliação de dados em cenários com poucos recursos.

Em conjunto, estas contribuições destacam o papel transformador da visão computacional (CV) na pesquisa em LIBRAS. Desde a extração de características manuais [49] até mecanismos avançados de atenção e redes neurais, a evolução das técnicas de reconhecimento visual continua a moldar o desenvolvimento de ferramentas de comunicação acessíveis para a comunidade surda no Brasil.

2.2 Processamento de Linguagem Natural

O processamento de linguagem natural (PNL) é um subcampo da IA que se concentra em permitir que as máquinas compreendam, interpretem e gerem linguagem humana [30]. No contexto

da tradução de LIBRAS, o PNL é essencial na fase de pós-processamento, onde sequências de sinais reconhecidos são convertidas em frases gramaticalmente corretas e semanticamente coerentes em português do Brasil [25].

Traduzir entre LIBRAS e português falado apresenta desafios específicos devido às diferenças estruturais entre as línguas de sinais e as línguas faladas [17]. Enquanto o português segue uma estrutura linear Sujeito-Verbo-Objeto, o LIBRAS é baseado em uma gramática espacial-visual, incorporando expressões simultâneas, expressões faciais e ordem de palavras flexível [19]. Portanto, os modelos de PLN projetados para a tradução de LIBRAS devem levar em consideração essas incompatibilidades linguísticas e semânticas [17, 19].

Vários estudos [1, 64, 68] exploraram arquiteturas de redes neurais de sequência para sequência, frequentemente aprimoradas com mecanismos de atenção ou modelos baseados em transformadores, para capturar dependências contextuais complexas. Por exemplo, Veríssimo et al. [64] examinaram o uso de redes de sequência para sequência para tradução automática do português brasileiro para LIBRAS, demonstrando o potencial de modelos neurais para produzir traduções mais naturais e fluidas.

Flores Brongar et al. [25] propuseram uma arquitetura de tradução que integra técnicas de conversão de fala em texto com técnicas de PLN para gerar resultados em LIBRAS a partir do português falado, destacando a importância do PLN na criação de pontes entre modalidades. Da mesma forma, Rocha et al. [45] apresentaram uma ferramenta de tradução que utiliza métodos de PLN clássicos, como análise morfológica e alinhamento semântico, para converter o texto de entrada em sequências de sinais.

Em termos de avaliação, os sistemas de tradução de LIBRAS baseados em PLN frequentemente dependem de métricas de tradução automática padrão para medir o quão de perto a saída do sistema corresponde às traduções humanas. Entre elas, a pontuação BLEU (Bilingual Evaluation Understudy) é uma das mais comuns, utilizada para avaliar a similaridade entre traduções geradas por máquinas e referências humanas, como em Veríssimo et al. [64] e Flores Brongar et al. [25]. Outras métricas, como ROUGE[34], METEOR [7], e medidas baseadas em classificação [58] como precisão e pontuação F1, também são usadas em tarefas que envolvem correspondência de frases predefinidas.

A eficácia dessas métricas de avaliação, no entanto, está intimamente ligada à disponibilidade e à qualidade dos conjuntos de dados anotados. Um dos desafios recorrentes na literatura é a falta de conjuntos de dados padronizados e disponíveis publicamente para a tradução de LIBRAS para o português. Como resultado, muitos estudos dependem de corpora personalizados ou colaborativos. Por exemplo, Silva et al. [53] desenvolveram um tradutor de LIBRAS com base em um corpus construído colaborativamente, enfatizando a necessidade de dados específicos do domínio nesta área de pesquisa.

Estes estudos destacam o papel essencial do PLN, quando combinado com CV e ML, na construção de sistemas eficazes de tradução de LIBRAS. Tais sistemas não apenas abordam um desafio técnico, mas também representam um passo em direção à maior inclusão e acessibilidade para a comunidade surda brasileira.

3 METODOLOGIA

Uma Revisão Sistemática da Literatura (SLR) é uma abordagem estruturada e padronizada para identificar, classificar e sintetizar estudos sobre um tópico específico [38]. Para padronizar ainda mais este método de pesquisa, adotamos o protocolo PRISMA [35] (Preferred Reporting Items

for Systematic Reviews and Meta-Analyses), que fornece diretrizes para ajudar a planejar, realizar e relatar revisões sistemáticas da literatura. Além disso, utilizamos a ferramenta Parsifal, uma plataforma online projetada para ajudar os pesquisadores a planejar e executar revisões sistemáticas da literatura, facilitando a definição do protocolo, o gerenciamento das strings de busca, a seleção de estudos e a extração de dados de forma colaborativa e organizada [37].

3.1 Perguntas de Pesquisa

Ao longo desta revisão sistemática da literatura, nosso objetivo é identificar estudos que investigam abordagens baseadas em inteligência artificial — incluindo, mas não se limitando a, aprendizado de máquina, aprendizado profundo, visão computacional e processamento de linguagem natural — para a tradução, reconhecimento e interpretação de LIBRAS.

Seguindo o protocolo PRISMA, definimos as seguintes Perguntas de Pesquisa (RQs) para a Revisão Sistemática da Literatura (RSL):

RQ1: Quais soluções baseadas em Inteligência Artificial estão sendo atualmente utilizadas em publicações para o reconhecimento de sinais de LIBRAS?**RQ2:** Quais são os indicadores de desempenho e os resultados relatados dos modelos existentes em tarefas de tradução de LIBRAS?**RQ3:** Quais conjuntos de dados são utilizados para treinar e avaliar esses modelos, e quais são suas principais características e limitações?

3.2 Fontes de Dados e Bibliotecas Digitais

Seis bancos de dados científicos foram selecionados como fontes primárias de pesquisa para realizar a RSL. A seleção foi baseada na relevância e abrangência dessas bibliotecas digitais nas áreas de Inteligência Artificial, Aprendizado de Máquina, Visão Computacional e áreas relacionadas.

A Tabela 1 apresenta os bancos de dados selecionados, incluindo repositórios internacionais e nacionais, visando garantir a diversidade e a qualidade das publicações recuperadas. As buscas foram realizadas utilizando as strings de busca específicas apresentadas na seção 3.1.

É importante mencionar que, além de fontes internacionais como ACM, IEEE e Springer, também foram incluídos bancos de dados nacionais como CAPES Journals e Sol SBC, visando cobrir estudos relevantes no contexto brasileiro, particularmente aqueles relacionados a LIBRAS.

Tabela 1: Bancos de dados científicos considerados para a revisão sistemática da literatura

Banco de dados	URL
ACM	https://dl.acm.org
CAPES	https://periodicos.capes.gov.br
IEEE Xplore	http://ieeexplore.ieee.org
ScienceDirect	http://www.sciencedirect.com
Sol SBC	https://sol.sbc.org.br/busca
Springer Link	http://link.springer.com

3.3 Estratégia de Busca

Após definir as perguntas de pesquisa e selecionar as bibliotecas digitais (Tabela 1), o próximo passo foi formular palavras-chave e sinônimos para construir a string de busca no Parsifal. Essas palavras-chave foram organizadas para corresponder aos componentes de cada pergunta de pesquisa, permitindo que o Parsifal gerasse strings de busca sistemáticas e reproduzíveis, garantindo, assim, rastreabilidade e consistência ao longo do processo de revisão.

- **Língua Brasileira de Sinais:** sinônimos incluem “*LIBRAS*” e “*Língua Brasileira de Sinais*”.
- **Inteligência Artificial:** *sinônimos incluem «Inteligência Artificial» e termos relacionados, como «Aprendizado de Máquina» e «Redes Neurais».*
- **Reconhecimento:** sinônimos incluem «Reconhecimento» e termos relacionados, como «Tradução» e «Detecção».

Estes termos foram combinados usando operadores booleanos (AND, OR) para construir a string de busca final. Esta estratégia visava recuperar estudos que se concentram em técnicas de inteligência artificial aplicadas à tradução de LIBRAS, incluindo avaliação de modelos, análise de conjuntos de dados e métricas de desempenho.

A string de busca final utilizada no Parsifal pode ser resumida da seguinte forma:

("Libras" OU "Língua Brasileira de Sinais" OU "língua brasileira de sinais") E ("inteligência artificial" OU "artificial intelligence" OU "machine learning" OU "aprendizado de máquina" OU "deep learning" OU "aprendizado profundo" OU "redes neurais" OU "neural networks") E ("reconhecimento" OU "translation" OU "tradução" OU "detecção")

3.4 Critérios de Seleção

A seleção dos estudos foi baseada em critérios de inclusão e exclusão predefinidos, conforme descrito abaixo.

3.4.1 Critérios de Inclusão.

- Artigos escritos em inglês ou português.
- Artigos completos (texto completo disponível).
- Estudos primários ou secundários.
- Estudos que envolvam a tradução do idioma de sinais (LIBRAS).

3.4.2 Critérios de Exclusão.

- Estudos envolvendo outras línguas de sinais (Não-LIBRAS).
- Abordagens que não empregam técnicas de Inteligência Artificial.
- Anais, resumos ou artigos curtos.
- Estudos publicados antes de 2015.
- Trabalhos focados na tradução *para* língua de sinais (em vez de *de* língua de sinais).
- Estudos que abordam apenas a tradução de sinais alfanuméricos.

3.5 Checklist de Avaliação da Qualidade

Para garantir a rigor metodológico da revisão sistemática, um Checklist de Avaliação da Qualidade foi aplicado para avaliar cada estudo selecionado. Cinco questões de avaliação foram definidas para analisar a relevância, transparência e qualidade metodológica dos estudos, conforme a seguir:

(1) O artigo descreve uma solução que utiliza Inteligência Artificial, Aprendizado de Máquina ou Visão Computacional aplicada à identificação de sinais de LIBRAS? (2) O conjunto de dados utilizado é público e acessível? (3) O artigo descreve o conjunto de dados utilizado para treinamento e avaliação? (4) O artigo define e aplica métricas de desempenho quantitativas para tarefas de tradução ou reconhecimento?

(5) O artigo apresenta e discute os resultados?

Cada questão foi pontuada de acordo com os seguintes critérios:

- **Sim:** 1.0 ponto
- **Parcialmente:** 0.5 ponto
- **Não:** 0.0 ponto

A pontuação máxima possível para cada estudo era de 5,0 pontos, e uma pontuação de corte de 3,0 pontos foi definida. Apenas os estudos que atingissem ou ultrapassassem esse limite foram considerados válidos para a inclusão na análise dos resultados. Essa avaliação permitiu a exclusão de estudos de baixa qualidade e garantiu que apenas trabalhos relevantes e metodologicamente sólidos contribuíssem para a síntese da evidência.

3.6 Formulário de Extração de Dados

Um formulário de extração de dados foi projetado para coletar sistematicamente informações relevantes de cada estudo selecionado. Os dados extraídos incluíam detalhes bibliográficos, características metodológicas e métricas de avaliação. A Tabela 2 resume os campos utilizados no processo de extração.

Tabela 2: Campos de extração de dados

Campo	Type	Valores
Repositório	Multi-seleção campo	ACM, CAPES Periódicos, IEEE, Science@Direct, Sol SBC, Springer Link
Year	Integer	Ano de publicação
Tipo de tarefa	Multi-seleção campo	Sinal Geração, Reconhecimento contínuo de sinais, Reconhecimento de sinais isolados, Isolado Sign Reconhecimento, de Texto, Outros
Abordagem	String	Método ou técnica used
Conjunto de dados utilizado	String	Nome do conjunto de dados
Tipo de entrada	Seleção múltipla campo	Imagem, Pose, Áudio, Texto, Vídeo
F1-score	Float	n/a
Accuracy	Float	n/a
Precision	Float	n/a
Revisão	Flutuação	n/a
Tempo de inferência	Flutuação	n/a
Pontuação BLEU	Flutuação	n/a

3.7 Estudos de Importação

Após realizar a busca nas bases de dados selecionadas, os estudos recuperados foram importados para a ferramenta Parsifal, conforme mostrado na Figura 1. Cada fonte representa a base de dados utilizada, juntamente com o número de estudos importados dela.

Os termos de busca foram adaptados de acordo com as especificações de cada banco de dados. É importante notar que algumas fontes, como as publicações da CAPES, não resultaram em nenhum estudo importado devido à falta de resultados relevantes ou a limitações técnicas no processo de extração.




Figura 1: Artigos selecionados versus aceitos por fonte

Os estudos importados de diferentes fontes prosseguiram para a fase de seleção, onde aqueles que atendiam aos critérios de inclusão predefinidos foram mantidos.

3.8 Seleção de Estudos

Durante a fase de Seleção de Estudos, todos os artigos importados foram analisados e classificados como *Aceitos*, *Rejeitados*, *Não Classificados* ou *Duplicados*, de acordo com os critérios de inclusão e exclusão predefinidos. Um total de 77 estudos foram avaliados usando a ferramenta Parsifal. Este processo foi realizado manualmente, analisando o título e o resumo de cada artigo para determinar sua inclusão.

A Figura 1 apresenta o número de *Selecionados* versus *Aceitos* artigos por fonte, onde cada coluna representa uma biblioteca ou banco de dados digital diferente. Pode-se observar que a maioria dos artigos selecionados foram publicados no IEEE Xplore e na ACM Digital Library.

A Figura 2 apresenta o diagrama de fluxo do PRISMA, que resume o processo de seleção dos estudos. Dos 77 registros identificados, 12 duplicados foram removidos e 65 registros permaneceram para a triagem. Com base na análise de título e resumo, 41 estudos foram excluídos, restando 24 para avaliação de elegibilidade. Um estudo foi excluído por não estar relacionado ao LIBRAS, resultando em 23 estudos incluídos na revisão final.

Cada estudo foi classificado manualmente por três revisores independentes, de acordo com os critérios de inclusão e exclusão predefinidos. Qualquer discordância foi discutida e resolvida por consenso entre os revisores. As categorias de classificação foram as seguintes:

- **Aceito:** Estudos que atendiam a todos os critérios de inclusão e abordavam o objetivo da pesquisa.
- **Rejeitado:** Estudos que não atendiam aos critérios de inclusão ou claramente se enquadravam nos critérios de exclusão.
- **Não classificado:** Estudos pendentes de decisão (nenhum permaneceu não classificado ao final do processo).
- **Duplicado:** Estudos identificados como duplicados de diferentes fontes.

A Figura 3 mostra a distribuição de artigos aceitos por ano de publicação. Embora as publicações tenham sido relativamente escassas entre 2015 e 2022, houve um aumento notável nos anos mais recentes, com 2023 e 2024 representando quase metade de todos os estudos aceitos. Em particular, 2024 contribuiu com sete artigos, sugerindo um crescente interesse na área e possivelmente refletindo os recentes avanços e o maior foco no campo.




Figura 2: Diagrama de fluxo PRISMA




Figura 3: Artigos por ano

4 RESULTADOS DE REVISÃO BIBLIOGRÁFICA

Esta seção apresenta os principais resultados obtidos a partir da análise dos estudos incluídos na revisão sistemática. Os resultados são organizados de acordo com as questões de pesquisa, com foco no desempenho do modelo, no uso de conjuntos de dados e na eficiência computacional.

As seções subsequentes fornecem um resumo estruturado dos estudos selecionados, apresentando as abordagens, práticas de avaliação e recursos empregados. Em vez de tirar conclusões precipitadas, cada questão é abordada individualmente, permitindo uma compreensão mais clara das estratégias tecnológicas adotadas, dos métodos de avaliação aplicados e das características dos conjuntos de dados utilizados.

Tabela 3: Resumo de Abordagens Baseadas em IA para Reconhecimento de Sinais em LIBRAS (RQ1)

Referência	Principal Técnica de IA	Dados de Entrada e Modalidade
Furtado et al. Sarma et al.	CNN (Inception-v3) com Transferência de Aprendizagem CNNs (UNET para segmentação, VGG para classificação)	Imagens visuais sem marcação do alfabeto LIBRAS. Imagens para segmentação semântica de mãos.
da Silva et al. [16] Alves et al. [4]	Rede neural 3D CNN (I3D) com duas ramificações CNN (ResNet-18) [27]	Imagens RGB e fluxo óptico de vídeos de sinais. 2D imagens esqueléticas geradas a partir do OpenPose [11] marcas.
de Avellar Sarmento e Ponti [17]	CNNs para características espaciais, combinadas com LSTMs para tarefas temporais	Marcas extraídas com MediaPipe [47] ou dados de vídeo.
Bharti et al. De Brito et al.	CNN (Inception-ResNet-v2) para classificação de imagens Long Short-Term Memory (LSTM)	Quadros-chave extraídos de vídeos de gestos dinâmicos. Dados sequenciais de pontos de referência da mão extraídos via MediaPipe [47].
Ruiz et al. [49]	BiLSTM e Transformer [62]para classificação	Características manuais do MediaPipe [47], YOLOv5 [29], e OpenFace [6].
Bastos et al. [8] Flores Brongar et al.	Camadas LSTM e Densas Transformer (T5) [42] em um modelo Sequence-to-Sequence	Dados de detecção do corpo completo do MediaPipe Holistic [47]. Texto em português proveniente da conversão de fala, utilizado para a linguagem de sinais. geração.
Silva et al.	Transformer [62] e LightConv [66] para a tradução automática,	Dados para o treinamento incremental do VLibras transla-
Fanucchi et al.	Vision Transformer (VideoMAE)	tor.
Silveira et al.	VAE-GAN condicional (adaptado de SynLibras)	Vídeos de linguagem de sinais para aplicações de realidade aumentada. Pontos-chave de pose ("figuras") para síntese de sinais em dispositivos móveis.
da Silva et al.	Arquitetura multi-fluxo com uma MLP para fusão	Múltiplos fluxos: imagem RGB, pose corporal e mão segmentação.
Silveira et al. [55]	VAE-GAN condicional [33] (modelo SynLibras)	Dados de pose para sintetizar (gerar) o sinalizador e os gestos- Verdadeiro.
Abreu e Dias, Abreu et al.	Aprendizado de Máquina Clássico (KNN, SVM)	Sinais EMG (Eletromiografia) e outros dados de sensores vestíveis.

4.1 Soluções baseadas em IA para o reconhecimento de LIBRAS (RQ1)

O reconhecimento e a interpretação do LIBRAS são si gnificativamente influenciados pela aplicação de IA, ML, DL e CV. Essas tecnologias são fundamentais no desenvolvimento de sistemas que traduzem gestos da língua de sinais em texto ou fala, melhorando a acessibilidade da comunicação para a comunidade surda e com dificuldades auditivas. Os estudos revisados empregam uma variedade de soluções baseadas em IA, desde arquiteturas de redes neurais sofisticadas até estratégias especializadas de extração de recursos e integração multi-modal. A Tabela 3 resume essas metodologias, detalhando as principais técnicas de IA e os modais de entrada utilizados nas obras referenciadas.

Arquiteturas de Deep Learning para Reconhecimento e Tradução de Sinais. Uma tendência proeminente na pesquisa em LIBRAS envolve o uso de várias arquiteturas de redes neurais profundas, principalmente para reconhecimento de sinais isolados e contínuos, bem como para geração e tradução de sinais:

- **Redes Neurais Convolucionais (CNNs):** As CNNs são fundamentais para o processamento de dados visuais em LIBRAS.– **Furtado et al.** [26] utilizaram o modelo Inception-v3, uma CNN com aprendizado por transferência para reconhecimento visual sem marcação do alfabeto LIBRAS.– **Sarma et al.** [52] implementaram a arquitetura UNET [48] para segmentação semântica de mãos, seguida por um modelo pré-treinado VGG16 [57] para classificação de gestos.

- Para o reconhecimento de sinais isolados em um contexto de saúde, **da Silva et al.** [16] propuseram uma arquitetura de duas fontes baseada em Redes Neurais Convolucionais 3D (especificamente I3D) [13], , processando imagens RGB e fluxo óptico.
- **Alves et al.** usaram uma CNN ResNet-18 [27] para classificar imagens de esqueleto 2D derivadas de OpenPose [11] para reconhecimento de sinais isolados.
- **de Avellar Sarmento e Ponti** investigaram CNNs (MobileNetV 2 [50], InceptionResNetV2 [60], ResNet50V2[27]) para extração de recursos espaciais, combinadas com LSTMs para classificação temporal em um estudo em conjunto de dados.
- **Bharti et al.** usaram CNNs como Inception-ResNet-v2 [60] para classificação de imagens dentro de uma nova técnica de extração de quadros-chave para reconhecimento de gestos e sinais dinâmicos.
- **Sarma et al.** também propuseram um sistema usando CNNs combinadas com módulos de atenção para segmentação semântica de mãos e reconhecimento de gestos, adaptando VGG16 [57] para classificação.

- **Redes Neurais Recorrentes (RNNs) e Memória de Curto Prazo (LSTM):** Essas redes são cruciais para lidar com a dinâmica temporal inerente à linguagem de sinais.– **De Brito et al.** [18] utilizaram um modelo LSTM, um tipo de RNN, para processar dados de landmarks de mãos extraídos via MediaPipe [47] para reconhecimento de sinais isolados.– **de Avellar Sarmento e Ponti** [17] combinaram LSTMs com CNNs ou landmarks do MediaPipe para classificação temporal de sinais isolados.

– **Ruiz et al.** [49] utilizaram uma Rede de Memória de Curto Prazo (BiLSTM) bidirecional para reconhecimento de linguagem de sinais em nível de palavra com base em recursos criados manualmente.

– **Bastos et al.** [8] desenvolveram um sistema usando camadas LSTM e Dense para reconhecimento contínuo e isolado de sinais, utilizando MediaPipe Holistic [47] para detecção do corpo.

• **Transformerse Modelos Sequência-para-Sequência:** Essas arquiteturas avançadas são cada vez mais utilizadas por sua capacidade de capturar dependências de longo alcance e informações contextuais complexas, particularmente em tarefas de tradução.

– **Flores Brongar et al.** [25] utilizaram um modelo de NLP chamado Sequence-to-Sequence (Seq2Seq) baseado na arquitetura Transformer para geração de sinais de LIBRAS para português, integrando a conversão de fala para texto. – **Ruiz et al.** [49] também usaram um modelo Transformer [62] para classificação em sua abordagem de reconhecimento de linguagem de sinais em nível de palavra. – **Silva et al.** [53] propuseram uma ferramenta chamada "Automation" que gerencia o treinamento incremental para o tradutor VLibras [65], utilizando redes neurais Transformer e LightConv com o framework Fairseq. – **Fanucchi et al.** [24] afinaram um Video Masked Autoencoder (VideoMAE) [61], uma arquitetura baseada em Vision Transformers (ViT), para reconhecimento de sinais de LIBRAS, com o objetivo de aplicações de realidade aumentada.

Extração de Características e Outras Modalidades de Entrada. Além da entrada de vídeo bruta, os estudos empregam várias técnicas para extrair características relevantes e utilizar diferentes modalidades de entrada:

• **Características Baseadas em Marcadores e Baseadas em Esqueleto:** – **De Brito et al.** [18] e **de Avellar Sarmento e Ponti** [17] utilizaram MediaPipe [47] para extrair pontos-chave (marcadores) de mãos, corpo e pose, que então servem como características para modelos RNN/LSTM. – **Ruiz et al.** [49] extraíram características manuais usando MediaPipe [47], YOLOv5 [29] (para detecção de mãos) e Open-Face [6] (para pose da cabeça e direção do olhar), seguido por Análise de Componentes Principais (PCA) para redução de dimensionalidade. – **Alves et al.** [4] converteram marcadores OpenPose [11] em imagens de esqueleto 2D usando o algoritmo Skeleton-DML, que foram então classificadas por uma CNN. – **Silveira et al.** [56] adaptaram o modelo SynLibras para dispositivos móveis, alterando a representação da pose de mapas de calor densos para "figuras de palito" derivadas de pontos-chave do GoogleMediaPipe.

• **Arquiteturas Multi-Fluxo:** Essas abordagens combinam diferentes fluxos de entrada ou tipos de recursos para uma compreensão mais abrangente. – **da Silva et al.** [16] utilizaram uma arquitetura de 3D CNN em duas fluxos, processando imagens RGB e fluxo óptico. – **da Silva et al.** [15] propuseram uma arquitetura de múltiplos fluxos, onde cada fluxo processa uma entrada distinta (imagem RGB, pose corporal e segmentação semântica da mão), com as saídas combinadas por uma Rede Neural Multicamadas (MLP) para classificação final.

• **Geradores de Modelos para Síntese de Língua de Sinais:**

– **Silveira et al.** [55] introduziram o SynLibras, um modelo de Condicional Variacional Autoencoder - Rede Generativa Adversarial (CVAE-GAN) projetado para separar a aparência do intérprete de sua pose gestual para a síntese de LIBRAS. – **Silveira et al.** [56] adaptaram ainda o SynLibras CVAE-GAN para gerar digitais intérpretes de LIBRAS em dispositivos móveis.

Abordagens Não Baseadas em Visão. Embora os avanços mais recentes dependam da visão computacional, alguns estudos exploram modalidades de entrada alternativas:

• **Tecnologias Baseadas em Sensores:**

– **Abreu e Dias** [2] e **Abreu et al.** [3] exploraram o uso de sinais EMG capturados por dispositivos vestíveis como o Myo Armband, juntamente com dados de acelerômetro, giroscópio e magnetômetro. Esses sinais foram usados para extrair recursos estatísticos, que foram então classificados por algoritmos como K-Vizinho Mais Próximo (KNN) e Máquina de Vetores de Suporte (SVM) para reconhecimento de dactilologia (fingerspelling).

A integração dessas diversas técnicas de IA, ML, DL e CV, frequentemente dentro de pipelines de ponta a ponta, é crucial para construir sistemas de tradução LIBRAS eficazes que abordem tanto os desafios técnicos quanto a necessidade social mais ampla de inclusão.

4.2 Métricas de Desempenho e Avaliação Relatadas (RQ2)

Avaliar o desempenho de sistemas baseados em IA para reconhecimento e tradução da Língua Brasileira de Sinais (LIBRAS) é crucial para garantir sua confiabilidade e aplicabilidade prática. Como se pode observar na Tabela 4, os estudos selecionados empregam um conjunto diversificado de métricas de avaliação, refletindo a natureza multimodal e multifacetada das abordagens. No entanto, na tarefa de tradução, são empregadas métricas do domínio da tradução automática, principalmente a pontuação BLEU (Bilingual Evaluation Understudy), que avalia a sobreposição entre os resultados gerados por máquinas e traduções humanas de referência. Alguns estudos também relatam o tempo de inferência, um aspecto importante para aplicações em tempo real.

Para tarefas de reconhecimento, métricas de classificação comuns, como **precisão**, **precisão**, **recall** e **F1-score**, são amplamente adotadas. Essas métricas fornecem informações sobre a correção e a robustez dos modelos, especialmente ao lidar com conjuntos de dados desequilibrados ou cenários multiclasse. No entanto, nas tarefas de tradução, são empregadas métricas do domínio da tradução automática, principalmente a pontuação BLEU (Bilingual Evaluation Understudy), que avalia a sobreposição entre os resultados gerados por máquinas e traduções humanas de referência. Alguns estudos também relatam o tempo de inferência, um aspecto importante para aplicações em tempo real.

A precisão é a métrica mais frequentemente relatada entre as obras analisadas. Ela reflete a proporção de previsões corretas e é particularmente útil em tarefas de classificação equilibradas. Por exemplo, em um cenário de conjunto de dados equilibrado, da Silva et al. [15] relatam uma precisão de 90,0% usando uma arquitetura multi-fluxo para reconhecimento de sinais em ambientes de saúde. Da mesma forma, Furtado et al. [26] alcançaram 97,0% de precisão com um modelo baseado em CNN (Inception-v3) usando aprendizado por transferência para reconhecimento de letras em LIBRAS, também com um conjunto de dados equilibrado. Em contraste, o desempenho tende a ser menor em contextos de avaliação mais desafiadores, como testes em conjuntos de dados diferentes. Como demonstrado por de Avellar Sarmento e Ponti [17], um modelo combinando CNNs e LSTMs alcançou 66,7% de precisão quando avaliado em conjuntos de dados diferentes.

e LSTMs.

A pontuação F1, que representa a média harmônica entre precisão e revocação, é amplamente utilizada para avaliar modelos de classificação. Ela é particularmente relevante em cenários com conjuntos de dados desequilibrados, pois equilibra o compromisso entre falsos positivos e falsos negativos, fornecendo uma medida mais representativa do desempenho do modelo do que apenas a precisão. No entanto, quando o conjunto de dados é equilibrado, a pontuação F1 geralmente produz valores muito próximos da precisão, pois a precisão e a revocação tendem a ser semelhantes. Isso pode ser observado no trabalho de da Silva et al. [16], onde um modelo de CNN 3D de duas vias para reconhecimento de sinais isolados alcançou uma pontuação F1 de 0,95, que corresponde estreitamente à precisão relatada. Um padrão semelhante é encontrado no trabalho de Alves et al. [4], onde os autores obtiveram uma pontuação F1 de 0,93 e valores de precisão e revocação de 0,94 e 0,93, respectivamente, em um conjunto de dados equilibrado.

As tarefas de tradução adotam critérios de avaliação específicos. A pontuação BLEU é a métrica mais comum neste domínio. Por exemplo, Flores Brongar et al. [25] empregaram uma arquitetura baseada em Transformer (T5) e obtiveram uma pontuação BLEU de 75,3 e um tempo de inferência de 0,91% em um sistema que integra a conversão de fala com a geração de LIBRAS. Isso demonstra o potencial de modelos baseados em NLP para lidar com a complexidade e a variabilidade semântica da geração de linguagem de sinais.

Em contraste com esses resultados mais altos, estudos que avaliaram modelos em vários conjuntos de dados ou usaram corpora disponíveis publicamente tendem a apresentar resultados mais baixos ou variáveis, refletindo os desafios da generalização. De Avellar Sarmento e Ponti [17], por exemplo, testaram várias combinações de CNN e LSTM em um cenário de cruzamento de conjuntos de dados e relataram uma precisão de apenas 66,7%, demonstrando o deslocamento de domínio entre as condições de treinamento e avaliação. Da mesma forma, Alves et al. [4], que usaram os conjuntos de dados Libras e SynLibras em diferentes contextos de avaliação, relataram uma precisão de 93,0% e um F1-score de 0,93, destacando a eficácia de recursos baseados em esqueletos, mas também demonstrando a sensibilidade do desempenho ao conjunto de avaliação.

Por outro lado, estudos que avaliaram modelos em vários conjuntos de dados ou usaram corpora disponíveis publicamente tendem a apresentar resultados mais baixos ou variáveis, refletindo os desafios da generalização. De Avellar Sarmento e Ponti [17], por exemplo, testaram várias combinações de CNN e LSTM em um cenário de cruzamento de conjuntos de dados e relataram uma precisão de apenas 66,7%, demonstrando o deslocamento de domínio entre as condições de treinamento e avaliação. Da mesma forma, Alves et al. [4], que usaram os conjuntos de dados Libras e SynLibras em diferentes contextos de avaliação, relataram uma precisão de 93,0% e um F1-score de 0,93, destacando a eficácia de recursos baseados em esqueletos, mas também demonstrando a sensibilidade do desempenho ao conjunto de avaliação.

A precisão e a revocação são relatadas de forma menos consistente nos estudos. Quando disponíveis, essas métricas ajudam a esclarecer o equilíbrio entre a identificação correta de sinais e a prevenção de falsos positivos. Por exemplo, Alves et al. [4] relataram uma precisão de 0,94 e uma revocação de 0,93, demonstrando um desempenho bem equilibrado de seu classificador. No entanto, muitos estudos omitem esses valores, concentrando-se em vez disso em métricas agregadas, como a precisão ou a pontuação F1, que podem obscurecer o desempenho em conjuntos de dados desequilibrados ou tarefas multi-classe.

Um subconjunto menor de estudos relata o tempo de inferência, o que é relevante para aplicações em tempo real ou embarcadas. Alves et al. [4] mencionam um tempo de inferência médio de 4,58 segundos por amostra, o que pode limitar a implantação em dispositivos móveis ou ambientes de baixa latência. Em contraste, Silveira et al. [4] exploraram estratégias de implantação móvel modificando os métodos de representação de pose em seu modelo gerativo em LIBRAS, obtendo um valor de 2,8 segundos.

pode limitar a implantação em dispositivos móveis ou ambientes de baixa latência. Em contrapartida, Silveira et al. [56] exploraram estratégias de implantação móvel, modificando os métodos de representação de pose e m seu modelo gerativo em LIBRAS, obtendo um valor de 2,8 segundos.

Apesar da adoção de métricas de avaliação padrão, não há consenso sobre práticas de benchmark no campo. Diferentes conjuntos de dados, tipos de tarefas (por exemplo, reconhecimento de sinais isolados versus tradução de gestos contínuos) e condições de avaliação (por exemplo, divisões independentes de sinais, cenários do mundo real) tornam difícil a comparação direta dos resultados relatados. Por exemplo, enquanto Flores Brongar et al. [25] obtiveram uma pontuação BLEU de 75,3% em uma tarefa de tradução, Silva et al. [53] relataram uma pontuação BLEU mais baixa de 39,26 usando o corpus VLibras e uma estratégia de treinamento colaborativa. Essas variações destacam a importância de contextualizar as métricas de desempenho dentro do contexto experimental de cada estudo.

Outro desafio metodológico recorrente é a falta de protocolos de avaliação padronizados em estudos. Como se vê na Tabela 4, os autores utilizam conjuntos de dados, arquiteturas de modelos e até mesmo métricas de desempenho diferentes, muitas vezes sem especificar detalhes importantes, como divisões de dados, variabilidade do sinalizante ou separação entre treinamento e validação. Essa heterogeneidade limita a comparabilidade e a reprodutibilidade dos resultados, mesmo quando métricas comuns, como precisão ou BLEU, são usadas.

Por exemplo, embora vários estudos relatem altos valores de precisão, como 99,87% em Abreu et al. ou 98,97% em Sarma et al., a falta de descrições metodológicas detalhadas, como o número de sinalizantes, classes de sinais ou cenários de teste, torna difícil avaliar se esses resultados resultam de generalização do modelo ou de overfitting em conjuntos de dados restritos. Por outro lado, estudos como Ruiz et al., que utilizam recursos criados manualmente e testam seus modelos em conjuntos de dados públicos, como o Libras Corpus, fornecem protocolos experimentais mais claros, contribuindo para a transparência na avaliação.

Embora amplamente utilizado em tarefas de tradução, o uso do BLEU como métrica primária tem suas limitações. Como demonstrado por Flores Brongar et al. [25] e Silva et al. [53], o BLEU não captura nuances semânticas, variabilidade do sinal ou diferenças sintáticas entre LIBRAS e português. Além disso, o uso de corpora paralelos personalizados, como no caso de Flores Brongar et al. [25], introduz incerteza adicional em relação à consistência e diversidade linguística das referências.

Finalmente, um aspecto crítico, mas pouco relatado, é a consideração de restrições de implantação no mundo real. Poucos estudos avaliam o desempenho do modelo em cenários independentes do sinal ou em ambientes naturais com iluminação, ângulos de câmera ou fundos variáveis. Embora Fanucchi et al. [24] dê um passo em direção à implementação realista, integrando seu modelo em um sistema de realidade aumentada, eles não fornecem métricas de desempenho detalhadas além da precisão de classificação.

Embora uma ampla gama de métricas de avaliação seja utilizada em estudos de reconhecimento e tradução de LIBRAS, a diversidade de configurações experimentais, a falta de referências padronizadas e a limitada divulgação de detalhes metodológicos representam barreiras à replicabilidade e generalização. Pesquisas futuras se beneficiariam de protocolos de avaliação compartilhados, conjuntos de dados abertos com diversos signantes e contextos, e a adoção mais ampla de práticas de relatórios transparentes.

Tabela 4: Resumo dos resultados da revisão bibliográfica (RQ2)

Referência	Year	Conjunto de dados	F1-score	Precisão	Precisão	Tempo de Inferência (segundos)	BLEU
Abreu et al. [3]	2016	Conjunto de dados próprio	-	0.99	-	-	-
Abreu e Dias [2]	2018	Conjunto de dados próprio	-	-	-	-	-
da Silva et al. [16]	2020	Conjunto de dados próprio	0.95	0.96	0.95	0.96	-
da Silva et al. [15]	2023	Conjunto de dados próprio	-	0.90	-	-	-
Furtado et al. [26]	2023	Conjunto de dados próprio	0.97	0.97	0.97	0.97	-
Ruiz et al. [49]	2023	Corpus Libras [20]	-	0.94	-	-	-
de Avellar Sarmento e Ponti [17]	2023	Entre conjuntos de dados	-	0.66	-	-	-
Bharti et al. [9]	2023	Dados de diferentes conjuntos	-	0.96	-	-	-
Flores Brongar et al.	2024	Conjunto de dados próprio	-	-	-	0.91	75.3
De Brito et al. [18]	2024	Conjunto de dados próprio	-	0.85	-	-	-
Alves et al. [4]	2024	Dados de diferentes conjuntos	0.93	0.93	0.94	0.93	4.58
Silva et al.	2021	Corpus VLibras	-	-	-	-	39.26
Bastos et al.	2015	BrSL	-	0.90	-	-	-
Sarma et al.	2021	BrSL [8]	-	0.98	-	-	-
Sarma et al. [52]	2024	BrSL [8]	-	0.98	-	-	-
Silveira et al. [55]	2022	SynLibras [54]	-	-	-	-	-
Silveira et al. [56]	2023a	SynLibras [54]	-	-	-	-	2.80
Veríssimo e Costa [63]	2020	Emo-PT [23]	0.94	0.94	-	-	-
Fanucchi et al. [24]	2024	MINDS-Libras [44]	-	0.84	-	-	-

4.3 Conjuntos de Dados: Características e Limitações (RQ3)

A maioria das pesquisas brasileiras sobre reconhecimento e tradução de Língua Brasileira de Sinais (LIBRAS) se baseia em conjuntos de dados específicos para treinamento e avaliação de modelos. Esses conjuntos de dados variam significativamente em escopo e complexidade: alguns são limitados à escrita manual (alfabeto manual), outros se concentram apenas em gestos da mão, enquanto conjuntos de dados mais abrangentes incorporam movimento da mão e do corpo, incluindo expressões faciais. Essa diversidade reflete os diferentes objetivos de cada estudo, que vão desde a classificação de gestos isolados até abordagens de tradução multimodal robustas. Além disso, os conjuntos de dados diferem em metodologia de coleta, qualidade de anotação, número de classes e disponibilidade pública.

Com base nos resultados da revisão sistemática, os seguintes conjuntos de dados surgiram como os mais relevantes na literatura, considerando seu uso frequente, desempenho relatado e alinhamento com os objetivos de pesquisa das obras analisadas:

V-LIBRAS [46] é um corpus paralelo que compreende 1.364 expressões em português traduzidas para Libras, totalizando 4.089 sinais. Até três diferentes signadores gravaram os sinais usando um *fundo de chroma key*, permitindo a substituição de cenas. O corpus está disponível publicamente por meio de um portal específico e é amplamente utilizado em sistemas de tradução automática.

MINDS-Libras [44] é um conjunto de dados multimodal desenvolvido na UFMG, contendo 20 sinais gravados cinco vezes por 12 signadores (aproximadamente 1.200 amostras). As gravações incluem vídeo RGB, profundidade e extração de pontos de referência do corpo e rosto. É utilizado para reconhecimento dinâmico de sinais e permite uma análise robusta da variabilidade entre signadores.

SynLibras-Pose [54] consiste em 1.133 vídeos de palavras em Libras com anotações automáticas (e editáveis) de 30 pontos-chave: 12 do corpo, 10 das mãos e 8 do rosto. Os dados foram extraídos do dicionário Libras-Português desenvolvido pela UFV [22]. Seu foco principal é a síntese de poses e a transferência entre signadores, o que é prático para métodos baseados em visão computacional e geração de imagens.

Corpus Libras (UFSC) [20] é um corpus linguístico aberto com vídeos espontâneos e solicitados em Libras. Ele é destinado a estudos linguísticos, documentação e análise sociolinguística. Possui ampla

representatividade, embora os protocolos de coleta e anotação de dados variem.

RBMT, NMT, e VLibrasBD [65] referem-se a abordagens e corpora de tradução utilizados na tradução automática de português-Libras. VLibrasBD é um corpus paralelo que alimenta o sistema VLibras, suportando a tradução baseada em regras (RBMT) e tradução automática neural (NMT). O acesso pode ser restrito ou sujeito a acordos institucionais [21].

SignBank(Brasil) [14] é um banco de dados lexical inspirado no modelo internacional SignBank, registrando sinais de Libras associados a glosses, vídeos e características linguísticas, como forma da mão e localização. É amplamente utilizado em estudos de descrição linguística, ensino e pesquisa em lexicografia de Libras.

Corpus Libras-Movement (UCI) [43] é um conjunto de dados clássico com 15 classes de movimentos manuais, cada um com 24 instâncias. Os dados foram extraídos de vídeos e convertidos em séries temporais bidimensionais (x, y) com 45 amostras por instância, que foram utilizadas em tarefas de classificação e agrupamento.

A Tabela 5 apresenta um resumo comparativo dos principais conjuntos de dados discutidos nesta seção, incluindo o número de classes, tipo de anotação, método de coleta, modalidades suportadas e tipo de acesso.

5 CONCLUSÕES

A análise técnica abrangente dos estudos selecionados revela uma evolução progressiva na aplicação de abordagens baseadas em Inteligência Artificial para o reconhecimento e tradução de LIBRAS. Uma forte dependência de arquiteturas baseadas em CNN é observada na maioria dos trabalhos, particularmente para o processamento de informações visuais, como gestos e movimentos corporais. Essas arquiteturas são frequentemente combinadas com técnicas de aprendizado por transferência para melhorar a generalização, mesmo em cenários com dados limitados. Modelos recorrentes, como LSTMs e BiLSTMs, são amplamente utilizados para modelar dependências temporais. Em contraste, Transformers e modelos Sequence-to-Sequence têm ganhado destaque recentemente devido ao seu desempenho superior na captura de nuances contextuais e sequenciais, especialmente em tarefas de tradução.

Tabela 5: Resumo comparativo dos principais conjuntos de dados de Língua Brasileira de Sinais (RQ3)

Conjunto de dados	Número de Classes	Número de Amostras	Tipo de Anotação	Método de Coleta	Modalidades	Acesso
V-LIBRAS	1.364 sinais	4.089 vídeos	Manual (vídeo + gloss)	Estúdio, chroma key, 3 sinalizadores	Apenas as mãos	Público
MINDS-Libras	20 sinais	~1, 200 vídeos	Marcas (RGB + profundidade)	RGB +profundidade + pose, 12 signantes	Mãos, rosto, corpo	Solicitar [44]
SynLibras-Pose	Não especificado	1.133 vídeos	Pontos-chave editáveis (30 pontos)	Do dicionário vídeos	Pose: mãos, rosto, body	Dados públicos
Corpus da UFSC	Não especificado	Não especificado	Glossos linguísticos	Falado espontaneamente provocado	Variação natural	Público [20]
VLibras-BD	Não especificado	Não especificado	Texto–vídeo	Alinhamento de texto–sinal	Sinais manuais	Restrito [65]
SignBank	Não especificado	Entradas lexicais	Glosas +metadados	Registro linguístico	Manual +fonologia	Público [14]
Movimento de Libras (UCI)	15 classes	24 instâncias	Séries temporais 2D (x,y)	De vídeo para tempo série	Trajetória da mão apenas	Público [43]

Estratégias multimodais estão sendo cada vez mais exploradas, integrando dados de movimento das mãos, expressões faciais e pose corporal para aumentar a robustez do reconhecimento. Frameworks como MediaPipe, OpenPose e YOLOv5 são frequentemente usados para extração de pontos e esqueletos, fornecendo entradas estruturadas para CNNs e RNNs. Arquiteturas multi-fluxo também aparecem como um padrão de design-chave, permitindo a combinação de diferentes tipos de entrada (por exemplo, imagens RGB, estimativa de pose, fluxo óptico) para fusão abrangente de recursos. Alguns estudos investigaram modelos generativos (por exemplo, CVAE-GANs [33]) para síntese de sinais e animação de avatares, particularmente visando aplicações móveis e de realidade aumentada.

Apesar desses avanços tecnológicos, padrões específicos de divergência são evidentes. Embora alguns estudos priorizem o reconhecimento de sinais isolados, outros se concentram na tradução contínua, aprendizado independente do sinalizante ou interação em t empo real. As estratégias de anotação também diferem co nsideravelmente, com alguns autores desenvolvendo conjuntos de dados manuais, enquanto outros utilizam corpora públicos como V-LIBRAS, MINDS-Libras e SynLibras-Pose [54]. Os protocolos de avaliação também variam, abrangendo desde a precisão e o F1-score até matrizes de c onfusão e avaliações qualitativas, o que dificulta comparações diretas entre estudos.

Em termos de desempenho, estudos recentes (2022–2023) relataram taxas de precisão mais altas, frequentemente superiores a 90%—em comparação com os esforços anteriores. Essa melhoria provavelmente se deve à crescente disponibilidade de conjuntos de dados anotados e à ampla adoção do aprendizado por transferência. No entanto, o desempenho ainda é sensível à complexidade da tarefa (por exemplo, digitação de sinais versus tradução de frases completas), à qualidade dos dados e às modalidades consideradas.

O campo também apresenta fragmentação, incluindo pistas faciais e componentes não manuais. Embora a integração multissensorial seja reconhecida como benéfica, muitos modelos ainda se limitam a sinais manuais, negligenciando elementos gramaticais cruciais transmitidos através de expressões faciais e movimento da cabeça. Essa inconsistência prejudica a generalização e a completude dos sistemas propostos.

Diante destas descobertas, esta revisão destaca o progresso significativo e a heterogeneidade metodológica neste campo de pesquisa. A diversidade de a bordagens demonstra a riqueza do campo e ressalta a necessidade de padronização. Conjuntos de dados compartilhados, benchmarks de avaliação unificados e esque mas de anotação típicos facilitam a reprodutibilidade e permitem comparações mais justas entre estudos. Abordar estes desafios é essencial para avançar nos sistemas de reconhecimento de LIBRAS em direção à implantação no mundo real e para um impacto social mais amplo.

Superar estes desafios é fundamental para impulsionar os sistemas de reconhecimento de LIBRAS em direção à implantação no mundo real e para um impacto social mais amplo.

6 QUESTÕES ABERTAS

Apesar dos recentes avanços impulsionados por arquiteturas de aprendizado profundo e estratégias multimodais, ainda existem várias questões em aberto no reconhecimento e tradução de LIBRAS. Um desafio recorrente é a integração limitada de características não manuais, como expressões faciais, direção do olhar e movimentos da cabeça—elementos que transmitem informações gramaticais e emocionais essenciais em LIBRAS. Embora existam ferramentas para extrair esses sinais, sua aplicação em modelos de reconhecimento e tradução ainda é pouco explorada, o que dificulta o progresso em direção a sistemas mais naturais e linguisticamente precisos.

Outro aspecto importante é a necessidade de expandir o desenvolvimento de conjuntos de dados em larga escala, equilibrados e multimodais. Iniciativas existentes, como V-LIBRAS [46], MINDS-Libras [44], e SynLibras- Pose [54] representam progresso, mas não abrangem totalmente a diversidade de classes, representação de signantes e cobertura de modalidades necessárias para aplicações mais amplas. Essa situação desafia a criação de modelos capazes de lidar com diversos contextos de uso, especialmente em ambientes que exigem robustez a variações linguísticas e visuais. Além disso, o reconhecimento contínuo de sinais, o processamento contextual da linguagem e a interpretação de interações complexas ainda são áreas pouco exploradas.

A ausência de padronização metodológica também representa um desafio. Esquemas de anotação heterogêneos e a falta de protocolos de avaliação unificados dificultam a comparação de resultados e a consolidação dos avanços. Métricas como precisão, F1-score e BLEU são usadas de forma inconsistente em estudos, muitas vezes sem considerar as características linguísticas do LIBR AS. Em particular, apesar de serem amplamente adotadas na tr adução automática, o BLEU é inadequado para capturar as diferenças sintáticas e semânticas entre o LIBRAS e o português.

Aspectos relacionados ao tempo e à variabilidade do sinalizador também recebem pouca atenção. Protocolos longitudinais e independentes do sinalizador são cruciais para avaliar a consistência do modelo em cenários do mundo real, mas ainda são raros. Questões relacionadas ao implantação do sistema—como o tempo de inferência, o custo computacional e o desempenho em diferentes condições ambientais (por exemplo, iluminação, posicionamento da câmera)—também exigem mais investigação para permitir o uso eficaz em dispositivos móveis e embarcados.

Questões relacionadas à implantação do sistema—como o tempo de inferência, o custo computacional e o desempenho em diferentes condições ambientais (por exemplo, iluminação, posicionamento da câmera)—também exigem mais investigação para permitir o uso eficaz em dispositivos móveis e embarcados.

Abordagens baseadas em sensores (por exemplo, EMG, acelerômetros) mostram potencial para complementar sistemas de visão computacional, particularmente em ambientes restritos, mas ainda são pouco exploradas. Modelos generativos para síntese de sinais, com aplicações de animação e aumento de dados de treinamento, estão emergindo, mas exigem mais desenvolvimento para alcançar maior realismo, flexibilidade e aceitação do usuário.

Para avançar nessas áreas, a pesquisa futura deve:

- Desenvolver conjuntos de dados LI-BRAS em larga escala, multimodais e de acesso público;
- Estabelecer estruturas de anotação e avaliação padronizadas, incluindo protocolos específicos para tarefas e orientados ao usuário; • Explorar arquiteturas avançadas (por exemplo, Transformers, Video-MAE) em contextos independentes do usuário e em tempo real;
- Adote metodologias de design participativo com o envolvimento ativo da comunidade surda;
- Investigue técnicas de aprendizado com poucos recursos e estratégias de integração multimodal que vão além da entrada visual.

Abordar essas questões em aberto será decisivo para transformar os avanços experimentais em aplicações concretas capazes de promover uma comunicação mais acessível e inclusiva para a comunidade surda brasileira.

7 CONCLUSÃO

Esta revisão sistemática da literatura examinou o uso de abordagens baseadas em IA na tradução e reconhecimento da Língua Brasileira de Sinais. A revisão identificou uma forte prevalência de arquiteturas baseadas em CNN para classificação de gestos, com crescente integração de redes recorrentes (LSTMs), modelos baseados em Transformers e abordagens ou multi-ssim, ou multimodal.

Em todos os estudos revisados, o desempenho do modelo variou dependendo da complexidade do conjunto de dados, da cobertura da modalidade e do contexto de avaliação. Tarefas como a digitação de sinais com dados coletados por si mesmo alcançaram uma precisão acima de 95%, enquanto cenários de cruzamento de conjuntos de dados e independentes do sinalizador frequentemente relataram resultados mais baixos. Uma ampla gama de métricas de avaliação—including precisão, F1-score, BLEU e tempo de inferência—foram usadas, embora os protocolos de benchmark permaneçam inconsistentes e frequentemente sub-relatados.

A análise também revelou uma mudança gradual em direção ao uso de conjuntos de dados públicos, como Corpus Libras [20], , VLibras [46], , SynLibras-Pose[54], e MINDS-Libras [44], , embora muitos modelos ainda dependam de conjuntos de dados privados ou limitados. A falta de corpora e anotações padronizadas, juntamente com a modelagem limitada de sinais não manuais, como expressões faciais e postura corporal, continua sendo uma barreira significativa para a generalização e o uso em ambientes do mundo real.

Esta revisão contribui ao mapear o estado da arte, identificar limitações metodológicas e destacar direções futuras de pesquisa—especialmente nas áreas de qualidade de dados, padronização de avaliação e design inclusivo. No futuro, a colaboração i nterdisciplinar com a comunidade surda será essencial para garantir que as soluções baseadas em IA para LIBRAS sejam acessíveis, contextualmente relevantes e linguisticamente precisas.

8 LIMITAÇÕES, FRAQUEZAS E AMEAÇAS À VALIDADE

Esta revisão sistemática teve um escopo limitado à literatura sobre LIBRAS, utilizando uma estratégia de busca focada explicitamente nesta língua de sinais. Embora o processo de extração de dados tenha sido conduzido com cuidado, alguns estudos relevantes podem ter sido omitidos devido aos critérios de busca e limitações dos bancos de dados.

As descrições dos conjuntos de dados disponíveis eram predominantemente qualitativas, carecendo de métricas quantitativas detalhadas que pudessem aprofundar a análise comparativa. Além disso, a ausência de informações completas sobre os métodos de coleta e anotação de dados limitava a avaliação de potenciais vieses. Finalmente, como em qualquer revisão bibliográfica, o viés de publicação é uma preocupação, uma vez que estudos que reportam resultados menos favoráveis podem estar sub-representados.

Discordâncias entre os autores em relação à inclusão e exclusão de estudos foram resolvidas por meio de discussão, garantindo o consenso. A experiência de um autor com revisões sistemáticas foi fundamental ao longo do processo. As categorias de estudo foram definidas com base na literatura disponível nas obras selecionadas.

AGRADECIMENTOS

Os autores deste trabalho desejam agradecer à Coordenação de Aperfeiçoamento de Pessoal de Nível Superior - Brasil (CAPES) - Código de Financiamento 001, CNPq e FAPERGS pelo financiamento desta pesquisa.

REFERÊNCIAS

Bashaer Abdullah, Ghada Amoudi, e Hanan Alghamdi. 2024. Avanços no Reconhecimento de Língua de Sinais: Uma Revisão Abrangente e Perspectivas Futuras. *IEEE Access* PP (01 2024 1 1 10 1109 2024 3457692), – . <https://doi.org/10.1109/ACCESS.2024.3457692>.
[2] Filipe Abreu e Jorge Dias. Um Dataset para Reconhecimento de Dactilologia Baseado em Eletromiografia. In *Proceedings of the 9th International Conference on Advances in Computer-Human Interactions (ACHI 2016)*. IARIA, Lisboa, Portugal, 325–330. https://www.thinkmind.org/download.php?articleid=achi_2016_12_30_100793
[3] João Gabriel Abreu, João Marcelo Teixeira, Lucas Silva Figueiredo, e Veronica Teichrieb. 2016. Avaliando o Reconhecimento de Língua de Sinais usando o Myo Armband. (2016). [4] Carlos Eduardo G. R. Alves, Francisco De A. Boldt, e Thiago M. Paixão. 2024. Melhorando o Reconhecimento de Língua de Sinais Brasileira através da Representação de Imagens de Esqueleto. (2024). [5] Tejaswini Ananthanarayana, Priyanshu Srivastava, Akash Chintna, Akhil Santha, Brian Landy, Joseph Panaro, Andre Webster, Nikunj Kotecha, Shagan Sah, Thomastine Sarchet, Raymond Ptucha, e Ifeoma Nwogu. 2021. Métodos de Aprendizado Profundo para Tradução de Língua de Sinais. *ACM Trans. Access. Comput.* 14, 4, Artigo 22 2021 30 10 1145 3477498 (Outubro), páginas. <https://doi.org/10.1145/3477498>.
[6] Tadas Baltrušaitis, Amir Zadeh, Yao Chong Lim, e Louis-Philippe Morency. 2018. OpenFace 2.0: Ferramenta de Análise de Comportamento Facial. In *2018 13th IEEE International Conference on Automatic Face & Gesture Recognition (FG 2018)*. 59–66. <https://doi.org/10.1109/FG.2018.00019>.
[7] S. Satanjeev Banerjee e Alon Lavie. 2005. METEOR: Uma Métrica Automática para Avaliação de MT com Correlação Melhorada com Julgamentos Humanos. In *Proceedings of the ACL Workshop on Intrinsic and Extrinsic Evaluation Measures for Machine Translation and/or Summarization*. 65–72. [8] Igor L.O. Bastos, Michele F. Angelo, e Angelo C. Loula. 2015. Reconhecimento de Gestos Estáticos Aplicados à Língua de Sinais Brasileira (Libras). (2015). [9] S. Bharti, A. Balmik, e A. Nandy. 2023. Técnica inovadora de extração de quadros-chave baseada em correção de erros para reconhecimento de gestos de mão dinâmicos. *Neural Computing and Applications* (2023). [10] Danielle Bragg, Oscar Koller, Mary Bellard, Larwan Berke, Patrick Boudreau, Annelies Braffort, Naomi Caselli, Matt Huenerfauth, Hernisa Kacorri, Tessa Verhoeve, Christian Vogler, e Meredith Ringel Morris. 2019. Reconhecimento, Geração e Tradução de Língua de Sinais: Uma Perspectiva Interdisciplinar. In *Proceedings of the 21st International ACM SIGACCESS Conference on Computers and Accessibility (Pittsburgh, PA, USA) (ASSETS '19)*. Association for Computing Machinery, Nova Iorque, EUA, 16 31 10 1145 3308561 3353774 – . <https://doi.org/10.1145/3308561.3353774>.
[11] Zhe Cao, Gines Hidalgo, Tomas Simon, Shih-En Wei, e Yaser Sheikh. 2021. OpenPose: Estimação em Tempo Real de Poses de Múltiplas Pessoas 2D usando Campos de Afinidade de Partes.

- IEEE Transactions on Pattern Analysis and Machine Intelligence* 43, 1 (2021), 172–186. <https://doi.org/10.1109/TPAMI.2019.2929257> Fabio Cappabianco, Igor Ribeiro Ferreira de Matos, and Luiz Eduardo Galvão Martins. 2024. Uma Revisão Sistemática sobre Visão Computacional Aplicada à Língua de Sinais Brasileira. *Luiz Eduardo Galvão, Uma Revisão Sistemática sobre Visão Computacional Aplicada à Língua de Sinais Brasileira* (2024). João Carreira and Andrew Zisserman. 2017. Quo Vadis, Action Recognition? A New Model and the Kinetics Dataset. In *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. 4724–4733. <https://doi.org/10.1109/CVPR.2017.5020mdena> São Paulo Chapter. 2023. Brazilian Sign Language Datasets: UFV, INES, SignBank, V-Libras.
- <https://github.com/OmdenaAI/SaoPauloBrazilChapterBrazilianSignLanguage>. Acesso em: jul. 2025. D.R.B. da Silva, T.M.U. de Araújo, T.G. do Rêgo, L.C.S. Florêncio, A.F. Neto, and A.C. de Paiva. 2023. A multiple stream architecture for the recognition of signs in Brazilian sign language in the context of health. *Multimedia Tools and Applications* (2023). Diego R. B. da Silva, Tiago Maritan U. Araujo, Thais Gaudencio do Rêgo, and Manuella Aschoff Cavalcanti Brandão. 2020. A Two-Stream Model Based on 3D Convolutional Neural Networks for the Recognition of Brazilian Sign Language in the Health Context. (2020). Amanda Hellen de Avellar Sarmiento and Moacir Antonelli Ponti. 2023. A Cross-Dataset Study on the Brazilian Sign Language Translation. (2023). Aron Caiuá V. De Brito, Ana Patrícia F. M. Mascarenhas, Marco A.C. Simões, Ivanoé J. Rodowanski, Jorge Alberto P. De Campos, Josemar Rodrigues De Souza, and Jose Grimaldo Da Silva Filho. 2024. RoboSign: Improving Interaction Between Service-Robot and Hearing Impairments People. (2024). Ronice Müller de Quadros. 2006. *Gramática da Língua de Sinais Brasileira*. Editora Bookman, Porto Alegre, Brasil. Obra de referência sobre a estrutura linguística da LIBRAS. Universidade Federal de Santa Catarina (UFSC). 2020. Corpus Libras UFSC. <https://corpuslibras.ufsc.br>. Acesso em: jul. 2025. Giely M. C. de Souza. 2019. *Tradução Automática Português-Libras: Uma abordagem híbrida baseada em RBMT e NMT*. Ph. D. Dissertation. Universidade Federal de Santa Catarina. <https://repositorio.ufsc.br/xmlui/handle/123456789.187888> / Universidade Federal de Viçosa. . *Dicionário Online Bilingue Li-bras/Português*. <https://sistemas.cead.ufv.br/dicionariolibras>. Acesso em: 11 ago. 2025. Mariza Miola Dosciatti, Lohann Paterno Coutinho Ferreira, and Emerson Cabrera Paraiso. 2013. Identificando Emoções em Textos em Português do Brasil usando Máquina de Vetores de Suporte em Solução Multiclasse. In *Congresso Nacional de Iniciação Científica - CONIC*. Brasil. <https://www.researchgate.net/publication/277813389> Disponível em: <https://www.researchgate.net/publication/277813389>. Rodrigo Zempulski Fanucchi, Arlindo Rodrigues Galvão Junior, Gabriel da Mata Marques, Lucas Brandão Rodrigues, Anderson da Silva Soares, and Telma Wo-erle Lima Soares. 2024. Fine-Tuning a Video Masked Autoencoder to Develop an Augmented Reality Application for Brazilian Sign Language Interpretation. (2024). Andrew Flores Brongar, Jordan Zitzke Pinho, Rosa Vicari, Gisele Moraes Simas, and Regina Barwaldt. 2024. Improving Translation from Portuguese to Brazilian Sign Language with Speech-to-Text Integration Through Natural Language Processing. (2024). Silas Luiz Furtado, Jauvane C. De Oliveira, and Shervin Shirmohammadi. 2023. Interactive and Markerless Visual Recognition of Brazilian Sign Language Alphabet. (2023). Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. 2016. Deep Residual Learning for Image Recognition. In *2016 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*. –. <https://doi.org/10.1109/CVPR.2016.78>. Sepp Hochreiter and Jürgen Schmidhuber. . Long Short-Term Memory. *Neural Computation* 9, 8 (1997), 1735–1780. <https://doi.org/10.1162/neco.1997.9.8.1735> Glenn Jocher. 2020. *YOLOv5 by Ultralytics*. <https://doi.org/10.5281/zenodo.3908559> Daniel Jurafsky and James H. Martin. 2019. *Speech and Language Processing* (3 ed.). Pearson. Draft available at <https://web.stanford.edu/jurafsky/slp3/>. H Pallab Jyoti Dutta, Debajit Sarma, M.K. Bhuyan, and R. H. Laskar. 2020. Semantic Segmentation based Hand Gesture Recognition using Deep Neural Networks. (2020). Navroz Kaur Kahlon and Williamjeet Singh. 2023. Machine translation from text to sign language: a systematic review. *Universal Access in the Information Society* 22, 1 (2023), 1–35.
- Matthew J. Page, Joanne E. McKenzie, Patrick M. Bossuyt, Isabelle Boutron, Tammy C. Hoffmann, Cynthia D. Mulrow, Larissa Shamseer, Jennifer M. Tetzlaff, Elie A. Akl, Sue E. Brennan, Roger Chou, Julie Glanville, Jeremy M. Grimshaw, Asbjørn Hróbjartsson, Manoj M. Lalu, Tianjing Li, Elizabeth W. Loder, Evan Mayo-Wilson, Steve McDonald, Luke A. McGuinness, Lesley A. Stewart, James Thomas, Andrea C. Tricco, and Vivian A. Welch. 2021. The PRISMA 2020 statement: An updated guideline for reporting systematic reviews. *BMJ* 372 (2021), n71. <https://doi.org/10.1136/bmj.n71>. /bmj.n Papers with Code. . Inception-v3. <https://paperswithcode.com/method/inception-v3> Licença: CC-BY-SA. [37] Parsifal. n.d.. About Parsifal: Perform Systematic Literature Reviews. <https://parsifal/about/>. Accessed: 2025-08-11. [38] Michele D. Peters, Christina M. Godfrey, Deborah McInerney, Patricia Soares, Hanan Khalil, and Beverley J. Parker. 2015. The Joanna Briggs Institute Reviewers' Manual: Methodology for JBI Scoping Reviews. The Joanna Briggs Institute (2015). Available online: <https://nursing.lsuhsu.edu/JBI/docs/ReviewersManuals/Scoping-.pdf> [39] Presidência da República do Brasil. 2002. Lei no 10.436, de 24 de abril de 2002. http://www.planalto.gov.br/ccivil_03/leis/2002/110436.htm. Reconhece a Língua Brasileira de Sinais (Libras) como um meio de comunicação e expressão legal.. [40] Presidência da República do Brasil. 2005. Decreto no 5.626, de 22 de dezembro de 2005. http://www.planalto.gov.br/ccivil_03/_Ato2004-2006/2005/Decreto/D5626.htm. Regula a Lei no 10.436/2002 e estabelece a necessidade de acessibilidade para pessoas surdas na educação, na mídia e nos serviços públicos.. [41] Soraia Prieth, J. Alfredo Sánchez, and Josefina Guerrero. 2022. A Systematic Review of User Studies as a Basis for the Design of Systems for Automatic Sign Language Processing. *ACM Trans. Access. Comput.* 15, 4, Article 36 (Nov. 2022), 33 pages. <https://doi.org/10.1145/3563395> [42] Colin Raffel, Noam Shazeer, Adam Roberts, Katherine Lee, Sharan Narang, Michael Matena, Yanqi Zhou, Wei Li, and Peter J. Liu. 2020. Exploring the limits of transfer learning with a unified text-to-text transformer. *J. Mach. Learn. Res.* 21, 1, Article 140 (Jan. 2020), 67 pages. [43] UCI Machine Learning Repository. 2008. Libras Movement Dataset. <https://archive.ics.uci.edu/ml/datasets/Libras-Movement>. 15 classes de movimentos manuais. Acesso em: jul. 2025. [44] Tamires et al. Rezende. 2022. MINDS-Libras: Um Conjunto Multimodal para Sinais em Libras. <https://gitlab.com/tamiresrezende/minds-libras-database-analise-descritiva>. Acesso mediante solicitação. UFMG. Acesso em: jul. 2025. [45] Jampierre Rocha, Jeniffer Lensk, Tais Ferreira, and Marcelo Ferreira. 2020. Towards a Tool to Translate Brazilian Sign Language (Libras) to Brazilian Portuguese and Improve Communication with Deaf. (2020). [46] Ailton José Rodrigues and Emmanuel P. Barbosa. 2020. Corpus paralelo Português-Libras para tradução automática baseado em avatares 3D. <https://libras.cin.ufpe.br>. Acesso em: jul. 2025. [47] Karl Rohr. 2001. Landmark-based image analysis: using geometric and intensity models. Vol. 21. Springer Science & Business Media. [48] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. 2015. U-net: Convolutional networks for biomedical image segmentation. In *International Conference on Medical image computing and computer-assisted intervention*. Springer, 234–241. [49] Daniel Sánchez Ruiz, J. Arturo Olvera-López, and Ivan Olmos-Pineda. 2023. Word Level Sign Language Recognition via Handcrafted Features. *IEEE Latin America Transactions* (2023). [50] Mark Sandler, Andrew Howard, Menglong Zhu, Andrey Zhmoginov, and Liang-Chieh Chen. 2018. MobileNetV2: Inverted Residuals and Linear Bottlenecks. In *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*. 4510–4520. <https://doi.org/10.1109/CVPR.2018.00474> [51] Debajit Sarma, Hriday Jyoti Prasad Dutta, Krishna Singh Yadav, Sahin Ahmed, and Manash Hazarika. 2021. Attention-based hand semantic segmentation and gesture recognition using deep networks. *Evolving Systems* (2021). [52] Saurav Kumar Sarma, Hemanta Kalita, and Rumi Devi. 2024. Semantic Segmentation based Hand Gesture Recognition using Deep Neural Networks. In *Proceedings of the 2nd International Conference on Computer Vision and Robotics (CVR)* 2024 102 109 10 1007 978 981 99 9053 5_9. Springer, –. [53] <https://doi.org/10.1109/ICCV.2021.9470053> Marcos Silva, Tiago Araújo, Rostand Costa, Samuel Moreira, and Lucas Alves. 2021. Automation: Uma Ferramenta para a Evolução de um Tradutor Automático Português-Libras com Corpus Colaborativo. (2021). [54] José Silveira, Rodrigo Vieira, and Adriano Bastos. 2023. SynLibras-Pose Dataset. <https://doi.org/10.5281/zenodo.8415850> Acesso em: jul. 2025 [55] Wellington Silveira, Andrew Alaniz, Marina Hurtado, Luca Mendonça, and Rodrigo de Bem. 2022. SynLibras: A Disentangled Deep Generative Model for Brazilian Sign Language Synthesis. (2022). [56] Wellington Silveira, Andrew Alaniz, Marina Hurtado, Luca Mendonça, and Rodrigo de Bem. 2023. Towards Generating Digital LIBRAS Signers on Mobile Devices. (2023). [57] Karen Simonyan and Andrew Zisserman. 2014. Very deep convolutional networks for large-scale image recognition. *arXiv preprint arXiv:1409.1556* (2014). [58] Marina Sokolova and Guy Lapalme. 2009. A Systematic Analysis of Performance Measures for Classification Tasks. *Information Processing & Management* 45, 4

- (2009), 427–437. <https://doi.org/10.1016/j.ipm.2009.03.002> Esther de Oliveira Souza, Juliana Guimarães Faria, Layane Rodrigues de Lima, and Inês Martins. 2023. Conteúdo Digital em Libras: Um Estudo dos Canais de Comunicação de Surdos no Brasil no YouTube. *Comunicação e sociedade* 43 (2023), e023001. [60] Christian Szegedy, Sergey Ioffe, Vincent Vanhoucke, and Alexander Alemi. 2017. Inception-v4, inception-resnet and the impact of residual connections on learning. In *Proceedings of the AAAI conference on artificial intelligence*, Vol. 31. [61] Zhan Tong, Yibing Song, Jue Wang, and Limin Wang. 2022. VideoMAE: masked autoencoders are data-efficient learners for self-supervised video pre-training. In *Proceedings of the 36th International Conference on Neural Information Processing Systems* (New Orleans, LA, USA) (NIPS '22). Curran Associates Inc., Red Hook, NY, USA, Article 732, 16 páginas. [62] Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. 2017. Attention is all you need. *Advances in neural information processing systems* 30 (2017). [63] Vinícius Verissimo and Rostand Costa. 2020. Utilizando Data Augmentation e Redes Neurais para Melhorar a Análise de Emoções em Textos em Português Brasileiro. (2020).
- [64] Vinícius Veríssimo, Cecília Silva, Vitor Hanael, Caio Moraes, Rostand Costa, Tiago Maritan, Manuella Aschoff, e Thaís Gaudêncio. 2019. Um estudo sobre o uso de redes neurais de sequência para sequência para tradução automática do português brasileiro para LIBRAS. (2019). [65] Equipe VLibras. 2020. VLibrasBD - Corpus paralelo para tradução automática Português-Libras. Disponível mediante solicitação institucional ao projeto VLi-bras. [66] Felix Wu, Angela Fan, Alexei Baevski, Yann N Dauphin, e Michael Auli. 2019. Preste menos atenção com convoluções leves e dinâmicas. *arXiv preprint arXiv:1901.10430* (2019). [67] Hanaa ZainEldin, Samah A Gamel, Fatma M Talaat, Mansourah Aljohani, Nadiyah A Baghdadi, Amer Malki, Mahmoud Badawy, e Mostafa A Elhosseini. 2024. Silêncio não mais: uma revisão abrangente de inteligência artificial, aprendizado profundo e aprendizado de máquina para facilitar a comunicação de surdos e mudos. *Artificial Intelligence Review* 57, 7 (2024), 188. [68] Yanqiong Zhang e Xianwei Jiang. 2023. Avanços recentes em aprendizado profundo para reconhecimento de línguas de sinais. *CMES - Computer Modeling in Engineering and Sciences* (2023).